

Definição e Validação do Problema

1. Contexto e Cenário do Negócio

A organização foco deste estudo é uma empresa que lida com grandes volumes de processamento de dados (Big Data) e utiliza uma estratégia de nuvem híbrida ou multi-cloud. No cenário atual, a agilidade no desenvolvimento de pipelines de dados é priorizada, mas o controle financeiro sobre esses processos é reativo. A empresa utiliza provedores como AWS e Azure para processar suas cargas de trabalho, enfrentando variações constantes de custos baseadas em volume, tipo de instância e região geográfica.

2. Problema a ser resolvido

O problema central identificado é a **ausência de previsibilidade financeira e o aprisionamento tecnológico (Vendor Lock-in)** nos pipelines de engenharia de dados.

Atualmente, o custo operacional só é conhecido após a execução completa dos processos, quando a fatura da nuvem é emitida. Isso gera:

- **Risco de Overspending:** Gastos inesperados devido ao crescimento súbito do volume de dados ou queries ineficientes.
- **Inexistência de Planejamento Prévio:** O engenheiro de dados não possui uma ferramenta que estime o custo de um "job" antes de dispará-lo.
- **Rigidez de Infraestrutura:** A dificuldade de mover cargas de trabalho entre nuvens impede que a empresa aproveite variações de preço mais favoráveis em outros provedores.

3. Usuários e Stakeholders

- **Engenheiros de Dados:** Precisam de um "feedback" financeiro imediato sobre o impacto de suas transformações de dados.
- **Analistas de FinOps:** Necessitam de métricas para transformar o custo variável da nuvem em um modelo de orçamento previsível.
- **Gestão Executiva (CTO/CFO):** Buscam eliminar o risco de dependência de um único fornecedor e garantir que o processamento ocorra onde o custo-benefício for maior.

4. Recorte do Problema e Proposta de Solução

O projeto foca no desenvolvimento de um **Framework Cross-Platform com Foco em Predição de Custos de Dados**. A solução se baseia em dois pilares fundamentais:

4.1. Estimativa de Custos Antecipada (Pre-run Prediction)

Diferente das ferramentas de mercado que olham para o passado, o framework utilizará metadados e telemetria histórica para gerar uma **estimativa de custo prévia**. Antes do processamento iniciar, o sistema avalia o volume de dados e a complexidade da tarefa, cruzando essas informações com as tabelas de preços atuais das nuvens para informar o custo esperado da operação.

4.2. Estrutura Cross-Platform (Independência de Nuvem)

A solução utiliza uma arquitetura baseada em padrões universais (Containers e SQL agnóstico), permitindo que o pipeline seja executado em qualquer plataforma de nuvem sem necessidade de reescrita de código. Isso transforma a infraestrutura em uma *commodity*, onde a decisão de execução é baseada na eficiência financeira (escolha do provedor mais barato no momento).

5. Validação e Relevância Estratégica

A validade deste problema é confirmada pela crescente disciplina de **Data FinOps**, que busca trazer a consciência de custo para o centro da engenharia. Estrategicamente, o projeto resolve o "ponto cego" financeiro da empresa, permitindo uma governança de dados proativa. A modularização Cross-Platform garante que a empresa mantenha sua soberania tecnológica, podendo migrar suas operações de dados conforme as oportunidades de mercado e variações cambiais, garantindo a sustentabilidade financeira do negócio a longo prazo.