

Data FinOps:

Predição e Liberdade em Nuvem

O Problema Central: Custos Reativos e Aprisionamento Tecnológico

STATUS QUO

AWS / Azure → execução → FATURA

- Custo só é conhecido após emissão da fatura
- Controle financeiro 100% reativo
- Lock-in impede migração para nuvem mais barata



NOSSA SOLUÇÃO

Pre-run Prediction Framework

- Estima custo ANTES do 'Start'
- Cross-platform: AWS, Azure, GCP, On-Premise
- Previsibilidade financeira antecipada via metadados

"A verdadeira disciplina de Data FinOps começa ANTES do processamento — não após a fatura."

O Desafio de Validação: Convertendo Código em Negócio

Missão 1 — Usuário

Quem é o Engenheiro de Dados e quais as suas dores reais?

→ Validado com 4 entrevistas + mapa de empatia

Missão 2 — Mercado

Em quais segmentos/empresas a solução é massificável?

→ Validado com TAM/SAM/SOM quantificado + benchmarking

Missão 3 — Negócio

Como provar o diferencial competitivo e a viabilidade financeira?

→ Validado com matriz competitiva e BMC completo

Mapa de Empatia: O Engenheiro de Dados

Pensa / Sente

Medo de executar uma query pesada e estourar o orçamento mensal. Frustração com cortes de infraestrutura sem contexto técnico. Sente que é penalizado por algo que não controla.

Vê

Faturas com variações de 30–60% mês a mês. Dashboards de custo disponíveis apenas após o faturamento. Colegas de time escalando recursos sem visibility financeira.

Escuta

"A fatura da AWS veio R\$ 40 mil acima do previsto." "Precisamos cortar jobs não-essenciais até fim do mês." "O CFO quer relatório de custo por pipeline até sexta."

Fala / Faz

Busca autonomia técnica. Quer focar em engenharia, não em planilhas de custo pós-morte. Experimenta ferramentas de estimativa manual (sem sucesso consistente).

Validação com Usuários — Entrevistas com Engenheiros de Dados (1/2)

Pedro Alves, 31 | Data Engineer Sênior — Fintech

P: Como você controla o custo dos seus jobs hoje?

Não controlo. Olho a fatura do mês e torço para não ter surpresa. Às vezes aviso o gestor depois que o custo estourou.

P: Você mudaria de provedor se soubesse que economizaria 30%?

Mudaria sim, mas reescrever os pipelines para outro cloud é inviável. Se tivesse uma ferramenta que abstraísse isso, seria diferente.

Dor confirmada: custo reativo + lock-in bloqueando decisões racionais.

Camila Rocha, 28 | Analytics Engineer — E-commerce

P: Você já cancelou ou adiou algum job por medo do custo?

Várias vezes. Especialmente no fim do mês. A gente aprende na marra quais queries são 'pesadas' — não tem ferramenta que avise antes.

P: Quanto do seu tempo vai para questões de custo vs. engenharia real?

Pelo menos 20% do meu dia. Justificar custo para o gestor, renegociar budget, documentar o porquê de um job ter custado mais.

20% do tempo desperdiçado em burocracia de custo — ROI direto da solução.

Validação com Usuários — Entrevistas com Engenheiros de Dados (2/2)

Rafael Monteiro, 35 | Head of Data Engineering — Healthtech

P: Qual é sua maior dor de governança de dados em multi-cloud?

Visibilidade. Tenho jobs rodando em AWS e Azure simultaneamente e nenhuma ferramenta me diz o custo consolidado antes de executar. É sempre post-mortem.

P: Você pagaria por uma solução de estimativa pré-execução?

Pagaria. O nosso custo de nuvem é R\$ 380 mil/mês. Se eu conseguir economizar 15%, pago R\$ 10 mil/mês sem pestanejar.

Disposição real de pagar confirmada. ROI claro: economia supera o custo da ferramenta.

Juliana Ferreira, 29 | FinOps Analyst — Varejo Online

P: Como você lida com engenheiros que estouram o budget sem avisar?

É uma guerra fria. Eles querem agilidade, eu quero previsibilidade. Hoje mando relatório retroativo — quando vejo o dano, já aconteceu.

P: Uma estimativa pré-execução resolveria sua relação com a equipe técnica?

Completamente. Se o custo virasse um metadado antes do job rodar, o atrito desapareceria. Seria uma linguagem comum entre eng. e finanças.

A solução elimina atrito entre times técnicos e financeiros — valor organizacional além do técnico.

Declaração de Problema — HMW Statement

Como poderíamos **ajudar engenheiros de dados em operações multi-cloud** a **prever o custo de jobs antes da execução**, eliminando o overspending reativo e o aprisionamento tecnológico?

Quem

Engenheiros de Dados e FinOps Analysts
em empresas com gasto cloud > R\$
50k/mês

O quê

Visibilidade financeira pré-execução via
metadados + framework cross-platform
agnóstico

Por quê

Custo reativo gera desperdício médio de
15–30% e paralisa técnica por medo de
estourar budget

Canvas de Proposta de Valor

PERFIL DO CLIENTE

Dores

- Medo de estourar budget ao executar jobs
- Custo só conhecido após fatura (reativo)
- Lock-in impede migrar para cloud mais barata
- 20% do tempo em burocracia de custo

Tarefas do Cliente

- Desenvolver e executar pipelines de dados
- Controlar custos de infraestrutura cloud
- Reportar eficiência ao gestor/CFO
- Manter agilidade sem sacrificar orçamento

Ganhos Esperados

- Autonomia técnica sem ansiedade financeira
- Previsibilidade de custos antes de executar
- Liberdade para migrar entre provedores

MAPA DE VALOR

Aliviadores de Dor

- Estimativa de custo pré-execução via metadados
- Feedback financeiro instantâneo no workflow
- Alerta de threshold antes de disparar job caro
- Bloqueio automático (No-Go) se custo excede o limite

Criadores de Ganho

- Cross-platform: código não precisa ser reescrito
- Soberania tecnológica — foge do vendor lock-in
- ROI mensurável: saving gerado por escolha de provedor
- Linguagem comum entre engenharia e finanças

Produtos e Serviços

- SaaS com API de integração nativa (Dagster, Spark)
- Motor de predição cross-platform
- Dashboard de visibilidade financeira pré-run

Segmentação de Mercado com Dados Quantificados

TAM

US\$ 18,3 bi

Empresas com alto volume de processamento em Nuvem (Big Data genérico) em todo o mundo.

(mercado global de Cloud Cost Management, 2024 — MarketsandMarkets)

SAM

US\$ 4,1 bi

Organizações utilizando estratégia Multi-Cloud ativa (AWS + Azure + GCP) com dores reais de governança. Fonte: Flexera State of the Cloud 2024 — 89% das empresas enterprise usam multi-cloud.

(≈22% do TAM — organizações multi-cloud ativas)

SOM

US\$ 210 mi

Fintechs, Varejo Online e Healthtechs com gasto cloud > R\$ 50k/mês e margem sensível ao custo variável de infraestrutura. Estimativa: ~1.400 empresas elegíveis no Brasil (fonte: ABES 2024).

(5% do SAM — foco inicial BR + LATAM)

⚠ Solução de precisão para operações maduras — não para PMEs com setups simples.

Matriz Competitiva: Concorrentes Reais Mapeados

Capacidade	AWS Cost Explorer	Azure Cost Mgmt.	Apptio Cloudability	Harness CCM	Monte Carlo Data	Nosso Framework
Estimativa pré-execução	X	X	X	X	X	X
Cross-platform agnóstico	X	X	?	?	X	X
Prevenção ativa de vendor lock-in	X	X	?	?	X	X
Portabilidade SQL/Containers	X	X	?	?	X	X
Observabilidade de qualidade	X	X	X	X	X	?
Budget em tempo real (pós-run)	X	X	X	X	X	X
Integração nativa orquestradores	X	X	X	X	X	X

x Completo ? Parcial x Ausente — Nosso Framework é o ÚNICO preditivo E agnóstico simultaneamente.

Missão 3 — Business Model Canvas Completo

Parcerias-Chave

- Provedores cloud alternativos (OVH, Oracle Cloud)
- Consultorias de governança de dados
- Comunidades: Apache Airflow, dbt, Spark
- Distribuidores de software enterprise

Atividades-Chave

- Desenvolvimento do motor de predição
- Manutenção das integrações com APIs de preço cloud
- P&D de algoritmos de estimativa
- Suporte e onboarding técnico

Proposta de Valor

- Estimativa de custo PRÉ-execução via metadados
- Framework cross-platform agnóstico
- Integração nativa com orquestradores (Dagster)
- Elimina vendor lock-in
- No-Go automático se custo excede threshold
- Transforma custo variável em previsível
- ROI mensurável por job

Relacionamento c/ Clientes

- Self-serve via documentação e SDK
- Customer success para contas enterprise
- Comunidade open-source (camada básica)
- SLA e suporte dedicado (premium)

Segmentos de Clientes

- Engenheiros de Dados (usuário final)
- FinOps Analysts (comprador)
- CTO/CFO (aprovador)

Setores-alvo:

- Fintechs
- Varejo Online
- Healthtechs
- Scale-ups multi-cloud

Critério: gasto cloud > R\$50k/mês

Estrutura de Custos

- Infraestrutura cloud para o motor de predição (≈30%)
- Equipe de P&D e engenharia (≈45%)
- Manutenção de integrações e atualizações de preços cloud (≈15%)
- Marketing e vendas (≈10%)

Recursos-Chave

- Motor de predição (ativo core)
- Store de telemetria histórica (PostgreSQL/DuckDB)
- Banco de preços cloud atualizado
- Time de engenharia (4–6 devs)
- Parcerias com provedores cloud

Canais

- Integração nativa: Dagster, Spark
- Marketplace AWS/Azure
- Comunidades dev (GitHub, Slack)
- Marketing de conteúdo técnico (blog, talks)

Fontes de Receita

- Assinatura SaaS por volume de jobs preditos (R\$0,05–0,20/job)
- Success Fee: % do saving gerado pela troca de provedor (8–12%)
- Plano Enterprise: contrato anual por assento (R\$800–2.000/usuário/mês)

Alinhamento de Stakeholders — O Triângulo de Valor

Engenheiros de Dados

Incentivo: Agilidade e foco em código

Ganho: Feedback financeiro instantâneo, fim do medo de overspending culposos.

FinOps Analysts

Incentivo: Transformar custo variável em previsível

Ganho: Visibilidade prévia em vez de autópsias financeiras mensais.

Gestão Executiva (CTO/CFO)

Incentivo: Eliminar dependência e maximizar custo-benefício

Ganho: Soberania tecnológica + redução drástica de desperdício em nuvem.

"O atrito desaparece quando o custo se torna um metadado pré-execução não uma surpresa pós-fatura."

O Paradoxo das Ferramentas Nativas: Ação Pós-Morte

1. Preparação (Código)

2. Execução (Run)

3. Faturamento (Fatura)

Data FinOps Preditivo (nossa abordagem)

O custo esperado é calculado cruzando telemetria histórica e tabelas de preços das APIs cloud ANTES do 'Start'. O job só é disparado após aprovação do threshold financeiro configurado.

Visibilidade Reativa (concorrentes nativos)

O custo já ocorreu. AWS Cost Explorer, Azure Cost Management e Apptio mostram o gasto APÓS execução. O lock-in impede a fuga para provedor mais barato.

"A infraestrutura se torna commodity quando a decisão de execução é baseada na eficiência financeira momentânea."

Como Funciona na Prática: O Mecanismo No-Go do Dagster

Job Submetido

Engenheiro submete o job ao orquestrador Dagster via pipeline ou CI/CD.

Predição de Custo

Motor Python cruza metadados do Spark (volume, complexidade) com APIs de preço AWS/Azure em tempo real.

Avaliação do Threshold

Dagster compara estimativa com o orçamento definido para aquele asset/pipeline.

GO — Job Executado

Custo estimado dentro do threshold configurado.
Job enviado ao cluster Spark (AWS EMR / Azure HDInsight).
Telemetria real salva no store histórico para refinar futuras previsões.

NO-GO — Job Bloqueado

Custo estimado excede o orçamento do asset no Dagster.
Job não chega ao cluster — desperdício evitado antes de ocorrer.
Engenheiro recebe estimativa detalhada + sugestão de otimização.

"O sistema bloqueia automaticamente jobs que excedam o threshold configurado — o custo vira um guardião, não uma surpresa."

Arquitetura de Dados: Store de Telemetria Histórica

Sem Store (hoje)

- Cada job é tratado como se fosse o primeiro
- Motor de predição opera só com dados estáticos de preço
- Acurácia baixa — sem aprendizado histórico
- Não há linha de base para detectar anomalias de custo
- Engenheiro continua no escuro após cada execução



Store de Telemetria

PostgreSQL ou DuckDB
(embedded, baixo custo)

O que é armazenado:

- Volume de dados processado (GB/TB)
- Tempo de execução real
- Custo real faturado (pós-run)
- Tipo de job / asset Dagster
- Provedor utilizado (AWS/Azure/GCP)
- Predição feita vs. custo real

Uso: alimenta o modelo de inferência Python para refinar as próximas estimativas.



Com Store

- Predição se refina a cada execução
- Acurácia > 90% para jobs recorrentes
- Detecta anomalias: job que custou 3x mais que a média
- Base para relatórios de eficiência por pipeline
- Suporte ao Success Fee: comprova saving gerado

O store de telemetria transforma o motor de predição de estático para adaptativo — quanto mais jobs rodam, mais precisa fica a estimativa.

Plano de PoC: 5 Etapas Técnicas para Validar a Solução

1

Ingestão de Telemetria Histórica

Extração de logs de execuções passadas (Spark/YARN) para criar linha de base de consumo de recursos por tipo de job. Resultado: dataset inicial para treinar o motor de inferência.

2

Motor de Inferência em Python

Script que consome tabelas públicas de preço (AWS Pricing API + Azure Retail Prices API) e cruza com complexidade dos jobs (I/O, Shuffle, CPU estimados via Spark Query Plan). Resultado: estimativa de custo pré-run.

3

Containerização do Job Spark

Empacotamento de carga ETL padrão em imagem Docker garantindo idempotência técnica entre AWS EMR e Azure HDInsight. Resultado: mesmo código, qualquer nuvem, sem reescrita.

4

Dagster Gatekeeper (No-Go)

Sensor no Dagster que valida estimativa de custo frente a orçamento fictício antes de disparar o cluster Spark. Se exceder → job bloqueado. Resultado: validação do mecanismo de controle financeiro proativo.

5

Validação AWS vs. Azure

Execução do mesmo job containerizado em EMR (AWS) e Databricks (Azure). Comparação entre predição e fatura real. Meta: acurácia > 90%. Resultado: prova do diferencial cross-platform e precisão do motor.

Ao final do PoC: acurácia da predição validada + portabilidade cross-platform comprovada + mecanismo No-Go operacional.

Próximos Passos: Da Validação à Execução

Estado Atual

1

Modelagem de Negócios e
Arquitetura Teórica Concluída.
Entrevistas com 4 personas
validadas.

Curto Prazo

2

Desenvolvimento do MVP do
Motor de Predição.
Integração inicial com APIs de
preço AWS e Azure.
Protótipo funcional para demo.

Médio Prazo

3

PoC em 5 etapas em ambiente
simulado.
Validar precisão da estimativa
vs. fatura real.
Meta: acurácia > 90% em jobs
Spark.

Longo Prazo

4

Lançamento em beta fechado
com 3 empresas parceiras.
Modelo de receita ativo
(assinatura + success fee).
Expansão para GCP e On-
Premise.

O Desafio Original, Superado

Usuário

4 entrevistas confirmaram: medo do custo inibe agilidade. A predição pré-run e o mecanismo No-Go resolvem a dor raiz e resgatam 20% do tempo técnico.

Mercado

SOM definido: +/- 1.400 empresas elegíveis no Brasil. TAM global US\$18,3bi. Fintechs, Varejo Online e Healthtechs como beachhead.

Negócio

Benchmarking isolou o framework como única solução preditiva E agnóstica. BMC completo com store de telemetria, No-Go e PoC em 5 etapas.